

---

# Воспроизведение ALDA: zero-shot обобщение в визуальном RL без аугментации данных

---

Олег Жуков<sup>1</sup>

## Аннотация

Мы заново реализуем ALDA (Associative Latent Disentanglement). Метод добавляет к Soft Actor-Critic распутанное латентное пространство в стиле QLAE, в котором покомпонентные кодовые книги работают как ассоциативная память. Мы проверяем, обобщается ли такой агент на визуальные сдвиги распределения без дообучения и без какой-либо аугментации данных. Агент обучается на задаче *walker-walk* из DeepMind Control по пикселям в течение 1 млн шагов среды (2 сйда); периодически мы оцениваем его в среде со сдвигом цвета и в Distracting Control Suite (уровень easy: динамические фоны DAVIS, возмущения камеры и цвета). На обучающей среде агент набирает награду 778, при сдвиге цвета сохраняет 81% от неё, в Distracting CS — 43%, причём обе кривые на OOD-средах продолжают расти к концу обучения. Реконструкции показывают, что латентная модель переводит кадры с помехами обратно к виду обучающей среды. Однако величина этой ассоциативной поправки не предсказывает разрыв в награде между отдельными оценками.

## 1. Введение

Стратегии, обученные по пикселям, обычно перестают работать, когда меняется внешний вид сцены. Стандартное решение — аугментация данных (Yarats et al., 2021a; Hansen et al., 2021): во время обучения агенту показывают приближения тех изменений, которые встретятся при тестировании. ALDA (Batra & Sukhatme, 2025) обходится без аугментации. Метод обучает распутанное латентное представление с помощью квантования латентов (Hsu et al., 2023) и трактует квантованную латентную модель как ассоциативную память в духе сетей Хопфилда: при

тестировании кодировка вне обучающего распределения (OOD) в каждой латентной размерности притягивается к ближайшему запомненному значению. В идеале изменение фактора, не важного для задачи (например, фона), затрагивает лишь несколько латентов, и они возвращаются к знакомым значениям.

В этом отчёте описана реализация SAC+ALDA с нуля в одном файле на основе SAC из CleanRL (Huang et al., 2022). Агент обучается в DeepMind Control (Tassa et al., 2018) и проверяется на zero-shot перенос в Distracting Control Suite (Stone et al., 2021). Мы ставим один исследовательский вопрос: *действительно ли ассоциативная латентная модель срабатывает на OOD-наблюдениях и объясняет ли величина её поправки падение качества?* (раздел 6).

## 2. Метод

**SAC.** Базовый алгоритм — Soft Actor-Critic (Haarnoja et al., 2018): стратегия в виде гауссианы, пропущенной через tanh, два критика с целевыми сетями, обновляемыми усреднением Поляка, и автоматическая настройка температуры энтропии.

**Распутывание (QLAE).** Энкодер  $f_\theta$  переводит один RGB-кадр в непрерывный вектор  $z_{cont} \in \mathbb{R}^{n_z}$ . У каждой размерности  $j$  своя скалярная кодовая книга  $v_j \in \mathbb{R}^{|V|}$ , а декодер  $g_\phi$  восстанавливает кадр по квантованному латенту. Распутыванию способствуют сильное затухание весов  $f_\theta$  и  $g_\phi$  вместе с покомпонентным квантованием (Hsu et al., 2023).

**Ассоциация.** ALDA заменяет жёсткий  $\arg \min$  из QLAE на извлечение из современной сети Хопфилда (Ramsauer et al., 2020) отдельно по каждой размерности:

$$z_{d,j} = \sum_k \text{softmax}(-\beta |z_{cont,j} - v_{jk}|)_k v_{jk}. \quad (1)$$

При большом  $\beta$  это извлекает (почти) одно запомненное значение на размерность. Кодовая книга *не* подтягивается к выходам энкодера (нет  $\mathcal{L}_{quantize}$ ): её оптимизирует только функция потерь задачи (критика), поэтому значения работают как память, настроенная под задачу,

---

<sup>1</sup>Независимый исследователь. Связь с автором: Олег Жуков <zhukovol3q@gmail.com>.

Отчёт по тестовому заданию: воспроизведение ALDA (Batra & Sukhatme, 2025), октябрь 2026.

**Алгоритм 1** Обновление SAC+ALDA (один шаг градиента)

**Вход:** батч  $(o, a, r, o', d)$ ,  $o \in \mathbb{R}^{B \times 3k \times 64 \times 64}$   
 $x \leftarrow o$ , разложенный на  $Bk$  отдельных кадров  
 $z_{cont} \leftarrow f_\theta(x)$ ;  $z_d \leftarrow l_\psi(\text{sg}(z_{cont}))$  (1)  
 $\mathcal{L}_{ALDA} \leftarrow \text{MSE}(g_\phi(z_{cont} + \text{sg}(z_d - z_{cont})), x) + \text{MSE}(z_{cont}, \text{sg}(z_d))$   
 $h \leftarrow h_\gamma(z_d, \text{приведённый к форме } B \times k \times n_z)$   
 $y \leftarrow r + \gamma(1-d)(\min_i \bar{Q}_i(h', a') - \alpha \log \pi(a'|h')), a' \sim \pi(\cdot|h')$   
 $\mathcal{L}_Q \leftarrow \sum_i (Q_i(h, a) - y)^2$   
 шаг AdamW по  $(\theta, \phi, \psi, \gamma, Q)$  для  $\mathcal{L}_Q + \mathcal{L}_{ALDA}$   
**на каждом втором шаге:** обновить  $\pi$  и  $\alpha$  по  $\text{sg}(h)$ ;  
 обновить  $\bar{Q}$ ,  $\bar{h}_\gamma$  усреднением Поляка

Таблица 1. Гиперпараметры (одинаковы для обоих сидов).

| Параметр                                        | Значение                |
|-------------------------------------------------|-------------------------|
| Ёмкость буфера / размер батча                   | $10^6$ / 128            |
| Температура ассоциации $\beta$                  | 100                     |
| Латентов $n_z$ / значений в книге $ V $         | 12 / 12                 |
| Затухание весов $\lambda_\theta = \lambda_\phi$ | 0,1                     |
| Стек кадров / повтор действия                   | 3 / 4                   |
| Наблюдение                                      | $9 \times 64 \times 64$ |
| Скорость обучения / для $\alpha$                | $10^{-3}$ / $10^{-4}$   |
| Начальная температура $\alpha$                  | 0,1                     |
| Период обновл. актора / целевых                 | 2 / 2                   |
| Коэффициент Поляка $\tau$ / дисконт $\gamma$    | 0,005 / 0,99            |
| Размерность признаков $(z_Q, z_\pi)$            | 50                      |
| Случайные действия в начале                     | 1000 шагов агента       |

и энкодер должен научиться попадать в неё. Целевая функция ALDA:

$$\mathcal{L}_{ALDA} = \|g_\phi(\tilde{z}) - o\|_2^2 + \|z_{cont} - \text{sg}(z_d)\|_2^2 + \lambda_\theta \|\theta\|^2 + \lambda_\phi \|\phi\|^2, \quad (2)$$

где  $\tilde{z} = z_{cont} + \text{sg}(z_d - z_{cont})$  — straight-through оценка градиента,  $\text{sg}$  — остановка градиента. Второе слагаемое называется потерей привязки (commitment).

**Временная информация.** Стек из  $k=3$  кадров сворачивается в размерность батча: каждый кадр кодируется и проходит ассоциацию независимо, после чего  $k$  латентных векторов объединяет по времени небольшая одномерная свёрточная сеть  $h_\gamma$  (алгоритм 1). Так автокодировщик всегда работает с отдельными изображениями; авторы статьи показали, что это необходимо для распутывания.

### 3. Реализация

Код — один файл (alda.py, около 570 строк) и конфигурации YAML; все гиперпараметры взяты из таблицы в приложении статьи (табл. 1).

**Архитектура.** Энкодер и декодер повторяют приложение QLAE, только leaky ReLU заменены на GELU, как в ALDA. *Энкодер:* 4 блока [свёртка  $3 \times 3$  с шагом 1, свёртка  $3 \times 3$  с шагом 1, свёртка  $4 \times 4$  с шагом 2] шириной 32/64/128/256 каналов; после каждой свёртки идут GELU и InstanceNorm ( $64^2 \rightarrow 4^2$ ), затем два полносвязных слоя по 256 нейронов с ReLU и линейный слой в  $n_z=12$ . *Декодер* устроен как в StyleGAN:  $z$  проходит через двухслойную сеть и превращается в вектор стиля  $w$ ; обучаемый вход  $256 \times 4 \times 4$  увеличивается двенадцатью слоями транспонированной свёртки, выходы которых модулируются через AdaIN по  $w$ , а свёртка  $1 \times 1$  выдаёт RGB. *Латентная модель:* скалярные кодовые

книги  $12 \times 12$ , инициализированные как  $\text{linspace}(-1, 1)$ ,  $\beta=100$ . *Энкодер истории:* два слоя Conv1d (ядро 2, 64 канала, GELU) поверх латентов трёх кадров. Критик проецирует их выход линейным слоем в 50 признаков, за которыми идут две Q-сети ( $2 \times 1024$ , GELU); у актора своя 50-мерная проекция и сеть  $2 \times 1024$  с tanh-гауссовой стратегией.

**Маршрутизация градиентов.** Мы следуем своему прочтению рис. 2 статьи.  $\mathcal{L}_Q$  обучает Q-сети, энкодер истории и значения кодовой книги, но не проходит дальше  $z_{cont}$ : энкодер получает градиенты *только* от реконструкции и привязки. Актор использует выход энкодера истории критика с остановкой градиента, как в SAC+AE (Yarats et al., 2021b).

**Отклонения от статьи и инженерные решения.** (i) **Раздельное затухание весов.** С Adam и обычной L2-регуляризацией 0,1 градиент регуляризации подавлял градиент реконструкции, и в начале обучения энкодер схлопывался в константу. Поэтому мы используем AdamW (Loshchilov & Hutter, 2019), как в реализации самих авторов QLAE, с затуханием 0,1 только для энкодера и декодера. (ii) **Кодирование следующего наблюдения.** Кадры кодируются независимо, поэтому  $o'$  разделяет с  $o$   $k-1$  кадров; мы переиспользуем их латенты и для TD-цели кодируем только новый кадр. Результат тот же, а вычислений примерно вдвое меньше. (iii) **Эффективность.** Буфер воспроизведения хранит только последний кадр каждого перехода и собирает стеки при выборке; энкодер и декодер работают в смешанной точности bf16 (латентная модель, критик и актор остаются в fp32); сцена рендерится один раз на шаг агента, а не на каждый повтор действия. (iv) **Ограничение эпизода по времени** не считается терминальным состоянием, и целевое значение по-прежнему строится через бутстрэп.

Таблица 2. Награда при оценке, усреднённая за последние  $10^5$  шагов (11 оценок  $\times$  5 эпизодов). «Доля» — отношение к награде на обучающей среде.

| Среда         | Сид 1 | Сид 2 | Среднее | Доля |
|---------------|-------|-------|---------|------|
| Обучающая     | 722   | 833   | 778     | 1,00 |
| Сдвиг цвета   | 589   | 668   | 628     | 0,81 |
| DistractingCS | 329   | 339   | 334     | 0,43 |

#### 4. Постановка экспериментов

**Обучение.** Агент обучается на *walker-walk* по пикселям  $64 \times 64$  в течение  $10^6$  шагов среды ( $2,5 \cdot 10^5$  шагов агента, одно обновление градиента на шаг агента), 2 сйда. Каждый запуск занял около 9 часов на одной RTX 3090 вместе с оценкой. Аугментация не используется нигде: агент видит только стандартную сцену DMC.

**Zero-shot оценка.** Каждые  $10^4$  шагов среды мы проводим 5 детерминированных эпизодов ( $\tanh$  от среднего стратегии) в трёх средах с сйдаи, не пересекающимися с обучающими:

- **Обучающая среда:** исходная задача DMC.
- **Сдвиг цвета:** цветовое возмущение из DCS с  $\max\_delta=0,5$  без дрейфа. Цвета агента и пола сдвигаются на величину до  $\pm 0,5$  по каждому каналу RGB, один раз за эпизод. Это наша замена среды «color hard» из DMCG, которую использовали авторы; идея похожая, но среды не совпадают.
- **Distracting CS (easy):** на фоне динамические видео из валидационной части DAVIS 2017 (Pont-Tuset et al., 2017) (4 видео), плюс динамические возмущения камеры и цвета с масштабом 0,1 (Stone et al., 2021).

Кроме награды, при каждой оценке мы считаем латентные статистики по всем кадрам оценочных эпизодов: средний ассоциативный сдвиг  $|z_{cont} - z_d|$ , долю компонент  $z_{cont}$  за пределами диапазона своей кодовой книги, нормированную энтропию использования кодовой книги и MSE реконструкции относительно наблюдаемого кадра.

#### 5. Результаты

**Кривые обучения.** Рис. 1 и табл. 2 подводят итог. На обучающей среде оба сйда достигают награды 700–850 к 1 млн шагов, и кривая всё ещё растёт. Zero-shot качество появляется в обеих OOD-средах и растёт до конца обучения: при сдвиге цвета награда доходит примерно до 630 (81%), в Distracting CS — примерно до 330 (43%),




Рис. 1. Награда при оценке на *walker-walk* в зависимости от числа шагов среды. Линии — среднее по 2 сйдаи (скользящее среднее по 5 оценкам), заливка — разброс между сйдаи. OOD-среды во время обучения не встречаются.

тогда как случайно инициализированный агент получает около 30 во всех трёх средах. Разброс в OOD-средах большой: стандартное отклонение по 5 эпизодам одной оценки составляет 150–200 против 40–50 на обучающей среде. Часть эпизодов переносится почти идеально, часть проваливается; это согласуется с тем, что помехи выбираются заново в каждом эпизоде.

**Доля сохранённой награды.** Если разделить награду в OOD-среде на награду в обучающей (рис. 2, слева), уходит эффект того, что агент просто стал лучше решать саму задачу. В Distracting CS эта доля всё обучение держится примерно на уровне 0,35–0,5, так что абсолютный рост награды в DCS на рис. 1 в основном отражает прогресс на обучающей задаче. При сдвиге цвета доля проседает примерно до 0,6 между 0,3 и 0,8 млн шагов и восстанавливается примерно до 0,85 к 1 млн. Энтропия использования кодовой книги (рис. 2, справа) растёт первые  $2 \cdot 10^5$  шагов, а затем медленно увеличивается. На обучающих и OOD-кадрах она почти одинакова, то есть OOD-входы распределяются по запомненным значениям так же широко, как обучающие.

**Реконструкции.** На рис. 3 видна работа ассоциации. При сдвиге цвета перекрашенный агент (красный, зелёный, пурпурный) и тонированный пол декодируются как обычный оранжевый агент на синем полу, с правильной позой. В Distracting CS фон DAVIS (люди, велосипеды) полностью исчезает, и декодер рисует пол и небо из обучающей среды. Ошибки появляются в позе. На нескольких реконструкциях из DCS конечности размыты или расположены неверно, вероятно, потому, что возмущение камеры сдвигает агента в кадре, а такого важного для задачи изменения в обучающих данных не было.




Рис. 2. Слева: награда в OOD-среде как доля награды на обучающей среде (начиная с  $10^5$  шагов, скользящее среднее по 5 оценкам; заливка — разброс между сидами). Справа: нормированная энтропия использования кодовой книги на оценочных кадрах из каждой среды.



Рис. 3. Входы (верхняя строка каждой пары) и реконструкции  $g_\phi(z_d)$  (нижняя) после 1 млн шагов, сид 1. Сверху вниз: обучающая среда, сдвиг цвета, Distracting CS. Цвета и фоны DAVIS из OOD-сред заменены видом обучающей среды (оранжевый агент, синий пол в клетку), поза в основном сохраняется.

**Обход латентных переменных.** По рис. 4 видно, что отдельные латенты управляют понятными частями позы агента: одни строки двигают одну ногу вперёд-назад, строки 5 и 8 переводят корпус из вертикального положения в падение или лежащее, другие немного смещают тело по высоте или горизонтали. Внешний вид обучающей сцены никогда не меняется, поэтому ни один латент не кодирует фон или цвет. Это ожидаемо и означает, что с OOD-внешним видом может справиться только ассоциация: отдельного латента, который поглотил бы помеху, нет. Распутывание неидеально: латенты корпуса заодно сгибают ноги. Энтропия использования кодовой книги в конце обучения составляет 0,60 и 0,47 от максимума



Рис. 4. Обход латентных переменных после 1 млн шагов (сид 1). Строка  $i$  перебирает 12 отсортированных значений кодовой книги латента  $i$ , остальные латенты зафиксированы на  $z_d$  обучающего кадра.

(сид 1/2), то есть большинство размерностей используют лишь часть своих 12 значений.

## 6. Исследовательский вопрос: объясняет ли ассоциация обобщение?

Главное утверждение ALDA: латентная модель переводит OOD-латенты к значениям из обучающего распределения. Мы проверяем две вещи: (а) заметно ли больше ассоциативная поправка на OOD-кадрах? (б) связана ли её величина с потерей награды?




Рис. 5. Латентные статистики на оценочных кадрах в ходе обучения (среднее по 2 сидам, заливка — разброс между сидами). Слева: средний ассоциативный сдвиг  $|z_{cont} - z_d|$ . В центре: доля выходов энкодера за пределы диапазона их кодовой книги. Справа: MSE реконструкции  $g_\phi(z_d)$  относительно наблюдаемого (возможно, с помехами) кадра, логарифмическая шкала.

#### (а) На OOD-кадрах ассоциация срывает сильнее.

После первых  $2 \cdot 10^5$  шагов средний сдвиг  $|z_{cont} - z_d|$  в среднем в 1,73 раза больше на кадрах со сдвигом цвета и в 1,80 раза больше на кадрах DCS, чем на обучающих (рис. 5, слева). В начале обучения, пока энкодер ещё не привязался к кодовой книге, сдвиг велик во всех трёх средах, и на OOD он примерно в 2–3 раза больше, чем на обучающей. При этом OOD-кодировки *не* выходят за диапазон кодовой книги чаще (рис. 5, в центре). На обучающих кадрах около 9–10% выходов энкодера лежат за крайними значениями кодовой книги (энкодер проскакивает их, и ассоциация обрезает значение), а на DCS — лишь 1–3%. Значит, OOD-входы попадают *между* запомненными значениями, где мягкое извлечение Хопфилда с  $\beta=100$  должно выбрать одного из двух соседей и может выбрать не того. Ошибка реконструкции относительно кадра с помехами (рис. 5, справа) в 10 раз (цвет) и в 30 раз (DCS) выше, чем на обучающей среде, и не меняется в ходе обучения. Это согласуется с тем, что помеха отбрасывается, а не восстанавливается (рис. 3).

#### (б) Величина поправки не предсказывает потерю.

По всем оценкам после  $2 \cdot 10^5$  шагов (81 на сид,  $n=162$ ) корреляция Пирсона между разностью ассоциативных сдвигов (OOD минус обучающая) и разрывом в награде (обучающая минус OOD) равна 0,20 для сдвига цвета и  $-0,24$  для DCS. Обе корреляции слабые и разного знака. За время обучения сдвиг *уменьшается* (рис. 5, слева), а разрыв в награде в абсолютных значениях *растёт* (рис. 1). Средняя величина ассоциации плохо показывает, помогает ли она. Рис. 6 показывает, что слабая корреляция объясняется прогрессом обучения: у ранних оценок (тёмные точки) сдвиг большой, а разрыв маленький, потому что награда пока низкая везде. Среди поздних, светлых точек тренда не видно.

**Ответ.** Да, на OOD-наблюдениях ассоциативная латентная модель срывает сильнее. Качественно она делает то, что заявлено в ALDA: внешний вид помех переводится к виду обучающей среды. Но то, насколько сильно она сдвигает латенты, не предсказывает качество. Мы предполагаем, что качество зависит от того, сохраняют ли извлечённые значения важные для задачи факторы (позу): провалы в DCS на рис. 3 — это ошибки позы, а фон в реконструкцию не просачивается. Более точная диагностика измеряла бы ошибки извлечения в латентах, которые кодируют важные для задачи факторы, но для этого нужны истинные состояния среды для оценочных кадров. Это мы оставляем на будущее.

## 7. Ограничения и открытые вопросы

- **Охват.** До 1 млн шагов обучен только walker-walk с 2 сидами. Конфигурации для cartpole-balance, ball\_in\_cup-catch и finger-spin есть и проходят короткие тестовые запуски, но полностью не обучались. В статье 5 сидов и 4 задачи.
- **Нет базовых методов.** Мы не обучали SAC+AE, SVEA и вариант SAC+QLAE с тем же бюджетом, поэтому не можем приписать OOD-награду именно ассоциации. Самый информативный следующий эксперимент — абляция, заменяющая уравнение (1) жёстким квантованием.
- **Среды.** Наш сдвиг цвета — это цветовое возмущение из DCS, а не среда «color hard» из DMCG; DCS оценивается только на уровне easy.
- **Неоднозначности.** В таблице статьи указан Adam; мы используем AdamW для энкодера и декодера (раздел 3). Точная маршрутизация градиентов и архитектура энкодера истории восстановлены по рис. 2 статьи и могут отличаться от кода авторов.




Рис. 6. Ассоциативный сдвиг (OOD минус обучающая среда) и разрыв в награде (обучающая минус OOD) для каждой оценки, оба сида, оценки после  $2 \cdot 10^5$  шагов. Цвет показывает прогресс обучения; линия — подгонка методом наименьших квадратов.

## 8. Заключение

Наша однофайловая реализация SAC+ALDA учится решать walker-walk по пикселям и без всякой аугментации переносится без дообучения на незнакомые сдвиги цвета (81% награды на обучающей среде) и частично на Distracting Control Suite (43%). Обе OOD-кривые продолжают расти по ходу обучения. Реконструкции показывают, что ассоциативная латентная модель переводит наблюдения с помехами к виду обучающей среды. Однако средняя величина её поправки не объясняет оставшийся разрыв в качестве; по-видимому, он вызван ошибками в позе агента при сдвиге камеры.

## Код и данные

Код, конфигурации и скрипты для графиков доступны по адресу <https://github.com/zxclwnq/test-alda>. Обучение: `python alda.py configs/walker_walk.yaml seed=1`. Графики: `python report/plots.py ru` и `python report/plots_extra.py ru` (без аргумента `ru` — с английскими подписями).

## Влияние работы

Цель этой работы — развитие области машинного обучения. У неё много возможных общественных последствий, но ни одно из них, на наш взгляд, не требует отдельного обсуждения.

## Список литературы

Batra, S. and Sukhatme, G. S. Zero-shot generalization of vision-based RL without data augmentation. In *Proceedings of the 42nd International Conference on Machine Learning*, 2025.

Haarnoja, T., Zhou, A., Abbeel, P., and Levine, S. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *Proceedings of the 35th International Conference on Machine Learning*, pp. 1861–1870, 2018.

Hansen, N., Su, H., and Wang, X. Stabilizing deep Q-learning with ConvNets and vision transformers under data augmentation. In *Advances in Neural Information Processing Systems*, volume 34, pp. 3680–3693, 2021.

Hsu, K., Dorrell, W., Whittington, J., Wu, J., and Finn, C. Disentanglement via latent quantization. In *Advances in Neural Information Processing Systems*, volume 36, pp. 45463–45488, 2023.

Huang, S., Dossa, R. F. J., Ye, C., Braga, J., Chakraborty, D., Mehta, K., and Araújo, J. G. CleanRL: High-quality single-file implementations of deep reinforcement learning algorithms. *Journal of Machine Learning Research*, 23 (274):1–18, 2022.

Loshchilov, I. and Hutter, F. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019.

Pont-Tuset, J., Perazzi, F., Caelles, S., Arbeláez, P., Sorkine-Hornung, A., and Van Gool, L. The 2017 DAVIS challenge on video object segmentation. *arXiv preprint arXiv:1704.00675*, 2017.

Ramsauer, H., Schäfl, B., Lehner, J., Seidl, P., Widrich, M., Adler, T., Gruber, L., Holzleitner, M., Pavlović, M., Sandve, G. K., et al. Hopfield networks is all you need. *arXiv preprint arXiv:2008.02217*, 2020.

Stone, A., Ramirez, O., Konolige, K., and Jonschkowski, R. The distracting control suite – a challenging benchmark

for reinforcement learning from pixels. *arXiv preprint arXiv:2101.02722*, 2021.

Tassa, Y., Doron, Y., Muldal, A., Erez, T., Li, Y., de Las Casas, D., Budden, D., Abdolmaleki, A., Merel, J., Lefrancq, A., et al. DeepMind control suite. *arXiv preprint arXiv:1801.00690*, 2018.

Yarats, D., Fergus, R., Lazaric, A., and Pinto, L. Mastering visual continuous control: Improved data-augmented reinforcement learning. *arXiv preprint arXiv:2107.09645*, 2021a.

Yarats, D., Zhang, A., Kostrikov, I., Amos, B., Pineau, J., and Fergus, R. Improving sample efficiency in model-free reinforcement learning from images. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 35, pp. 10674–10681, 2021b.

## А. Визуализации для сида 2



Рис. 7. Сид 2 после 1 млн шагов. Слева: обход латентных переменных (как на рис. 4). Справа: реконструкции на обучающей среде, при сдвиге цвета и в Distracting CS (как на рис. 3).

## В. Динамика обучения

Ошибки реконструкции и привязки падают на порядок за первые  $5 \cdot 10^4$  шагов и затем продолжают медленно уменьшаться (рис. 8). Ошибка привязки остаётся на два порядка ниже ошибки реконструкции, то есть энкодер держится близко к кодовой книге без явного  $\mathcal{L}_{quantize}$ . Среднее  $Q$  растёт плавно, ошибка критика не расходится.

## С. Эволюция реконструкций и обходов латентов




Рис. 8. Статистики обучения по эпизодам (потери усреднены по обновлениям внутри эпизода, скользящее среднее по 20 эпизодам). Энтропия стратегии достигает целевого значения SAC  $-|A| = -6$  примерно за  $10^5$  шагов, после чего  $\alpha$  подстраивается, чтобы удерживать её. У сида 2 ошибка критика примерно вдвое выше, ошибки реконструкции и привязки тоже выше, но и награда у него выше.




Рис. 9. Входы и реконструкции после 0; 0,1; 0,3; 0,6 и 1 млн шагов (сид 1, из журнала изображений TensorBoard). Слева направо: обучающая среда, сдвиг цвета, Distracting CS. Уже с 0,1 млн шагов фоны и цвета из OOD-сред декодируются как обучающая сцена; дальше обучение в основном делает позу агента чётче.




Рис. 10. Обход латентных переменных после 0,1; 0,5 и 1 млн шагов (сид 1). На 0,1 млн большинство латентов почти не меняет изображение; к 0,5 млн несколько латентов управляют отдельными положениями конечностей и корпуса, а к 1 млн обходы становятся плавнее.